

КРИПТОГРАФІЯ
КОМП'ЮТЕРНИЙ ПРАКТИКУМ №1

Експериментальна оцінка ентропії на символ джерела відкритого тексту

Мета: Засвоєння понять ентропії на символ джерела та його надлишковості, вивчення та порівняння різних моделей джерела відкритого тексту для наближеного визначення ентропії, набуття практичних навичок щодо оцінки ентропії на символ джерела.

Виконали: Михайленко Ростислав , Міроненко Микита.

1. Мета роботи

Засвоїти поняття ентропії на символ джерела та його надлишковості, дослідити моделі джерела відкритого тексту та експериментально оцінити вплив розподілу символів і залежностей між ними на ентропію природної мови.

2. Вихідні дані та попередня обробка тексту

Для дослідження використано російськомовний текст твору Л. М. Толстого «Війна і мир». Розмір вихідного текстового файлу становив 3,229 МБ, кодування — UTF-8-SIG.

У програмі застосовано такі правила попередньої обробки:

- усі літери переводяться до нижнього регістру;
- до алфавіту включено 33 російські літери; у варіанті з пробілами пробіл є окремим символом алфавіту;
- усі символи, що не належать до заданого алфавіту, замінюються пробілами;
- послідовності пробілів та інших розділових символів стискаються до одного пробілу;
- для варіанта без пробілів усі пробіли вилучаються з попередньо нормалізованого тексту.

Після нормалізації довжина тексту з пробілами становила 1 776 648 символів, без пробілів — 1 485 071 символ.

3. Короткий опис програмної реалізації

Програму реалізовано мовою Python. Код розділено на декілька модулів:

- `text_processing.py` — читання файлу, визначення кодування та нормалізація тексту;
- `entropy_calc.py` — підрахунок частот, формування біграм, обчислення H_1 , H_2 та надлишковості;
- `experiments.py` — формування послідовностей А, Б, В, Г, Д та проведення експериментів;
- `results_io.py` — формування CSV-файлів і текстового підсумку;

- main.py — керування послідовністю обчислень.

Для оцінювання ентропії окремих символів використано формулу:

$$H_1 = -\sum p_i \log_2 p_i.$$

Для біграм обчислювалася питома ентропія на один символ:

$$H_2 = -(1/2) \sum p_{i,j} \log_2 p_{i,j}.$$

Біграми формувалися двома способами: зі зсувом на один символ (перекривні) і зі зсувом на два символи (неперекривні).

4. Частоти символів і біграм

4.1. Частоти символів

Символ	Кількість (з пробілами)	p (з пробілами)	Кількість (без пробілів)	p (без пробілів)
—	291577	0.164116	—	—
о	169910	0.095635	169910	0.114412
е	122390	0.068888	122390	0.082414
а	122235	0.068801	122235	0.082309
и	98446	0.055411	98446	0.066290
н	97600	0.054935	97600	0.065721
т	86266	0.048555	86266	0.058089
с	78093	0.043955	78093	0.052585
л	75331	0.042401	75331	0.050726
в	67304	0.037883	67304	0.045320
р	66048	0.037176	66048	0.044475
к	51372	0.028915	51372	0.034592
д	45146	0.025411	45146	0.030400
м	44384	0.024982	44384	0.029887
у	41308	0.023251	41308	0.027816
п	38548	0.021697	38548	0.025957
я	33325	0.018757	33325	0.022440
ь	29491	0.016599	29491	0.019858
г	29259	0.016469	29259	0.019702
ы	28716	0.016163	28716	0.019336
б	26424	0.014873	26424	0.017793
з	25244	0.014209	25244	0.016999

Символ	Кількість (з пробілами)	p (з пробілами)	Кількість (без пробілів)	p (без пробілів)
ч	21633	0.012176	21633	0.014567
й	17204	0.009683	17204	0.011585
ж	15474	0.008710	15474	0.010420
ш	13737	0.007732	13737	0.009250
х	12853	0.007234	12853	0.008655
ю	9469	0.005330	9469	0.006376
ц	5299	0.002983	5299	0.003568
э	4745	0.002671	4745	0.003195
щ	4229	0.002380	4229	0.002848
ф	2922	0.001645	2922	0.001968
ъ	656	0.000369	656	0.000442
ё	10	0.000006	10	0.000007

Таблиця 1 — Частоти символів у нормалізованому тексті

Найчастішим символом у тексті з пробілами є пробіл ($p = 0,16412$). Серед літер найбільшу частоту має «о» ($p = 0,09564$). Після видалення пробілів найчастішими залишаються «о», «е», «а», «и», «н».

4.2. Частоти біграм

У таблицях нижче символ «_» позначає пробіл.

№	Перекрив на біграма	p	Неперекривна біграма	p
1	о_	0.022187	о_	0.022209
2	и_	0.018774	и_	0.018847
3	е_	0.017030	е_	0.017068
4	а_	0.016321	а_	0.016348
5	_н	0.015668	_н	0.015568
6	_с	0.015647	_с	0.015528
7	_п	0.015317	_п	0.015302
8	_в	0.014888	_в	0.014940
9	то	0.013819	то	0.013816
10	_о	0.012118	_о	0.012096

Таблиця 2 — Найчастіші біграми у тексті з пробілами

№	Перекрив на біграма	p	Неперекр ивна біграма	p
1	то	0.016887	то	0.017016
2	ст	0.013168	ст	0.013039
3	на	0.012231	на	0.012296
4	ов	0.011568	ов	0.011533
5	ал	0.010921	ал	0.010878
6	он	0.010835	го	0.010818
7	не	0.010786	он	0.010777
8	го	0.010731	не	0.010742
9	но	0.010546	но	0.010541
10	ко	0.010305	ко	0.010327

Таблиця 3 — Найчастіші біграми у тексті без пробілів

Для перекривних біграм було використано 1 776 647 спостережень у тексті з пробілами та 1 485 070 — без пробілів. Для неперекривних — відповідно 888 324 та 742 535. Отже, спосіб із перекривними біграмами використовує майже вдвічі більше статистичних даних.

5. Обчислення H_1 та H_2

Варіан т тексту	H_0	H_1	H_2 , перекривні	H_2 , неперекривн і	$ \Delta H_2 $
З пробілами	5.087463	4.377737	3.967451	3.967703	0.000252
Без пробілів	5.044394	4.466734	4.147256	4.147518	0.000262

Таблиця 4 — Значення ентропії для основного тексту

У тексті з пробілами H_2 для перекривних біграм дорівнює 3,967451 біт/символ, а для неперекривних — 3,967703 біт/символ. Різниця становить лише 0,000252 біт/символ. Для тексту без пробілів різниця також дуже мала — приблизно 0,000262 біт/символ. Це свідчить про стабільність оцінки на великому обсязі тексту.

Після вилучення пробілів H_1 збільшилося з 4,377737 до 4,466734 біт/символ, а H_2 — приблизно з 3,96745 до 4,14726 біт/символ. Пробіл у вихідному тексті має дуже високу ймовірність, тому робить розподіл символів більш нерівномірним і зменшує ентропію на символ.

6. Дослідження впливу розподілу символів на ентропію

До виконання обчислень було сформульовано прогноз:

$$H_1(B) < H_1(A) < H_1(V).$$

Послідовність Б складається з повторення одного символу, тому її ентропія повинна бути нульовою. Природний текст А має нерівномірний розподіл символів, а випадкова послідовність В генерується рівноймовірно та повинна мати найбільшу ентропію.

Послідовність	Опис	H_1 , біт/символ
А	Фрагмент природного російськомовного тексту	4.383031
Б	Повторення одного символу	0.000000
В	Випадкова рівноймовірна послідовність	5.087363

Таблиця 5 — Результати експерименту А–Б–В

Отриманий порядок повністю відповідає прогнозу: $0 < 4,383031 < 5,087363$. Значення H_1 для випадкової послідовності В практично збігається з $H_0 = 5,087463$, що відповідає рівноймовірному незалежному вибору символів.

7. Дослідження залежностей між символами

Для послідовностей Г і Д використано однаковий двосимвольний алфавіт {а, б} та однакові частоти символів. У Г символи випадково перемішані, у Д утворено періодичну структуру «абабаб...».

Прогноз: H_1 для Г і Д має бути однаковим; H_2 повинно суттєво відрізнятися, причому менше значення очікується для періодичної послідовності Д. Для Д також очікується відмінність між перекривними та неперекривними біграмами.

Послідовність	H_1	H_2 , перекривні	H_2 , неперекривні
Г	1.000000	0.999999	0.999999
Д	1.000000	0.500000	0.000000

Таблиця 6 — Результати експерименту Г–Д

Для обох послідовностей $H_1 = 1$ біт/символ, оскільки частоти «а» та «б» однакові. Водночас у випадковій послідовності Г $H_2 \approx 1$, а у періодичній Д $H_2 = 0,5$ для перекривних біграм і 0 для неперекривних. Це демонструє, що H_1 не враховує порядок символів, тоді як H_2 виявляє залежність між сусідніми символами.

Для Д перекривні біграми чергуються як «аб», «ба», «аб», «ба», тому існують дві приблизно рівноймовірні біграми і $H_2 = 0,5$ біт/символ. За неперекривного поділу маємо тільки «аб|аб|аб|...», тобто одну біграму з імовірністю 1, тому $H_2 = 0$.

8. Експериментальна оцінка умовної ентропії в CoolPinkProgram

У програмі CoolPinkProgram було проведено серії експериментів для порядків $n = 10, 20$ і 30 . Для $n = 10$ та $n = 30$ виконано по 50 експериментів, для $n = 20$ — 53 експерименти. У кожному випадку за контекстом із попередніх символів вгадувався наступний символ, а програма формувала межі оцінки умовної ентропії.

$H^*(10): 1.68979107263327 < H < 2.38704372667954$; кількість експериментів — 50.

мови. Тому ці оцінки слід інтерпретувати як наближені інтервали, а не точні значення.

9. Оцінювання надлишковості джерела

Надлишковість оцінювалася за формулою:

$$R = 1 - H / H_0.$$

Для основного тексту значення H_0 визначалося як $\log_2(m)$, де m — кількість символів алфавіту. Для тексту з пробілами $H_0 = 5,087463$, без пробілів $H_0 = 5,044394$.

Варіант	Модель	Ентропія	Надлишковість
3 пробілами	H_1	4.377737	13.95%
3 пробілами	H_2 , перекривні	3.967451	22.02%
3 пробілами	H_2 , неперекривні	3.967703	22.01%
Без пробілів	H_1	4.466734	11.45%
Без пробілів	H_2 , перекривні	4.147256	17.78%
Без пробілів	H_2 , неперекривні	4.147518	17.78%

Таблиця 8 — Надлишковість для моделей H_1 та H_2

Оцінка	Інтервал H	Інтервал надлишковості R
$H^{(10)}$	1.689791...2.387044	53.08%...66.79%
$H^{(20)}$	2.322614...3.156098	37.96%...54.35%
$H^{(30)}$	1.573731...2.142059	57.90%...69.07%

Таблиця 9 — Інтервальні оцінки надлишковості за CoolPinkProgram

Урахування залежностей між символами зменшує оцінку ентропії та збільшує надлишковість. Для тексту з пробілами R за H_1 становить 13,95%, а за H_2 — близько 22,02%. Для довшого контексту інтервальні оцінки надлишковості є ще більшими. Це відображає передбачуваність природної мови: що більше контексту враховується, то більше закономірностей можна використати для передбачення наступного символу.

10. Аналіз результатів

1. Чому природний текст має меншу ентропію на символ, ніж випадкова рівноймовірна послідовність символів того самого алфавіту?

У природній мові символи мають нерівні ймовірності та утворюють закономірні послідовності. У нашому експерименті для природного тексту А отримано $H_1 = 4,383031$, тоді як для рівноймовірної випадкової послідовності В — $H_1 = 5,087363$, майже максимальне $H_0 = 5,087463$. Отже, нерівномірність частот природної мови зменшує невизначеність.

2. Яку інформацію про джерело враховує H_2 , але не враховує H_1 ?

H_1 залежить лише від частот окремих символів і не враховує їх порядок. H_2 використовує частоти пар сусідніх символів, тому враховує локальні залежності між ними. Для основного тексту з пробілами $H_1 = 4,377737$, а $H_2 \approx 3,967451$ біт/символ, що показує додаткову передбачуваність завдяки зв'язкам між сусідніми символами.

3. Чи можуть два тексти мати однакове H_1 , але різне H_2 ? Наведіть приклад із виконаних експериментів.

Так. Послідовності Г і Д мають однакові частоти «а» та «б», тому для обох $H_1 = 1$. Проте для випадкової Г $H_2 \approx 1$, а для періодичної Д $H_2 = 0,5$ при перекривних і 0 при неперекривних біграмах. Отже, однакові частоти символів не означають однакових залежностей між ними.

4. Як вилучення пробілів вплинуло на отримані значення ентропії?

Після вилучення пробілів H_1 збільшилося з 4,377737 до 4,466734, а H_2 — приблизно з 3,96745 до 4,14726 біт/символ. У тексті з пробілами пробіл має ймовірність 0,16412 і є найчастішим символом, через що розподіл стає більш нерівномірним. Після його вилучення відносні частоти літер вирівнюються, тому ентропія на символ збільшується.

5. Чому оцінки H_2 для перекривних і неперекривних біграм можуть дещо відрізнятися?

Ці способи використовують різні вибірки біграм. Перекривний варіант бере біграму з кожної сусідньої пари і використовує майже вдвічі більше спостережень. Неперекривний бере лише пари з кроком 2. Для великого

природного тексту різниця виявилася дуже малою: 3,967451 проти 3,967703 біт/символ з пробілами, тобто близько 0,000252.

6. Чому значення H_1 , H_2 , $H^{(10)}$, $H^{(20)}$ та $H^{(30)}$ відрізняються?

Вони враховують різну кількість контексту. H_1 описує лише розподіл окремих символів, H_2 — зв'язки в парах, а $H^{(n)}$ у CoolPinkProgram оцінює передбачуваність наступного символу за довшим контекстом. Тому довший контекст може значно зменшувати невизначеність. Отримані інтервали CoolPinkProgram також залежать від обмеженої кількості дослідів і від вгадувань експериментатора, тому вони не зобов'язані бути строго монотонними.

7. Який із проведених експериментів найкраще демонструє залежності між послідовними символами?

Найнаочнішим є експеримент Г–Д. Обидві послідовності мають $H_1 = 1$, але різний порядок символів призводить до різкого розходження H_2 : приблизно 1 для випадкової Г та 0,5/0 для періодичної Д. Саме тому цей експеримент безпосередньо показує, що порядок і залежності не видно через H_1 , але вони відображаються в H_2 .

8. Як отримані результати пов'язані з можливістю стиснення природного тексту без втрати інформації?

Ненульова надлишковість означає, що текст містить передбачуваність і статистичні закономірності, які можна використати під час кодування. Для тексту з пробілами надлишковість за H_1 становить близько 13,95%, а за H_2 — близько 22,02%. Отже, урахування залежностей між символами виявляє додаткову надлишковість, яку потенційно може використати алгоритм стиснення без втрати інформації.

11. Висновки

У роботі було експериментально досліджено ентропію російського письмового тексту на рівні окремих символів, біграм і довшого контексту. Для природного тексту з пробілами отримано $H_1 = 4,377737$ та $H_2 \approx 3,96745$ біт/символ. Зменшення H_2 порівняно з H_1 підтверджує наявність залежностей між сусідніми символами.

Експеримент А–Б–В підтвердив вплив розподілу ймовірностей: ентропія дорівнює нулю для детермінованої послідовності, має проміжне значення для природного тексту та наближається до максимуму для рівноймовірної випадкової послідовності. Експеримент Г–Д показав, що однакове H_1 не гарантує однакового H_2 : порядок символів та їх залежності суттєво впливають на ентропію моделі другого порядку.

За допомогою CoolPinkProgram отримано інтервальні оцінки $H^{(10)}$, $H^{(20)}$ і $H^{(30)}$. Вони загалом нижчі за H_1 та H_2 , що узгоджується з більшою передбачуваністю наступного символу за наявності довшого контексту. Водночас оцінки мають значну статистичну похибку і залежать від обмеженої кількості експериментів та дій експериментатора, тому конкретні інтервали не утворили строго монотонної послідовності.

Оцінка надлишковості показала, що врахування залежностей між символами збільшує виявлену надлишковість природного тексту. Це пояснює можливість ефективного стискання текстової інформації без втрати змісту.