

Криптографія

Комп'ютерний практикум №1

**Експериментальна оцінка ентропії на символ джерела
відкритого тексту**

Виконали:
студенти групи ФБ-41
Александрова М. та Проценко Д.

Мета: Засвоєння понять ентропії на символ джерела та його надлишковості, вивчення та порівняння різних моделей джерела відкритого тексту для наближеного визначення ентропії, набуття практичних навичок щодо оцінки ентропії на символ джерела.

Хід роботи

1. Підготовка тексту

Для проведення експериментальних досліджень було обрано роман Т. Драйзера «Американська трагедія» у текстовому форматі

Проведено попередню обробку тексту в пайтон скрипті:

1. Весь текст переведено у нижній регістр

```
def clean_text(file_path):  
    with open(file_path, "r", encoding="utf-8") as f:  
        raw = f.read().lower()
```

2. Вилучено всі розділові знаки, цифри, латинські літери та спецсимволи

```
# Залишаємо тільки кирилицю (а-я, ё) та пробіли  
text_sp = re.sub(r"[^а-яё]", " ", raw)
```

3. Послідовності з декількох пробілів замінено на один пробіл

```
text_sp = re.sub(r"\s+", " ", text_sp).strip()
```

4. Сформовано два базові текстові файли:

text_with_spaces.txt (текст із пробілами, розмір алфавіту $m=34$)

text_without_spaces.txt (текст без пробілів, розмір алфавіту $m=33$)

```
text_nosp = text_sp.replace(" ", "")
```

```
# Збереження оброблених файлів для напарника  
with open("text_with_spaces.txt", "w", encoding="utf-8") as f:  
    f.write(text_sp)  
  
with open("text_without_spaces.txt", "w", encoding="utf-8") as f:  
    f.write(text_nosp)
```

2. Розрахунок статистичних характеристик тексту

Алгоритми та функції розрахунку

1. Обчислення ентропії монограм H_1 :

Оцінюється за формулою Шеннона $H_1 = - \sum_{i=1}^m p_i \log_2 p_i$, де p_i — відносна частота i -го символу в тексті (тобто його ймовірність):

```
def calc_h1(text):  
    n = len(text)  
    counts = Counter(text)  
    h1 = -sum((cnt / n) * math.log2(cnt / n) for cnt in counts.values())  
    return h1, counts, n
```

2. Обчислення питомої ентропії перетинальних біграм H_2 :

Формула розрахунку: $H_2 = - \frac{1}{2} \sum p(b) \log_2 p(b)$, де біграми формуються зі зсувом в 1 символ:

```
def calc_h2_overlapping(text):  
    bigrams = [text[i : i + 2] for i in range(len(text) - 1)]  
    n = len(bigrams)  
    counts = Counter(bigrams)  
    h2 = -0.5 * sum((cnt / n) * math.log2(cnt / n) for cnt in counts.values())  
    return h2, counts, n
```

3. Обчислення питомої ентропії неперетинальних біграм H_2 :

Формула аналогічна, але біграми виділяються кроком у 2 символи (без накладання):

```
def calc_h2_non_overlapping(text):  
    bigrams = [text[i : i + 2] for i in range(0, len(text) - 1, 2)]  
    n = len(bigrams)  
    counts = Counter(bigrams)  
    h2 = -0.5 * sum((cnt / n) * math.log2(cnt / n) for cnt in counts.values())  
    return h2, counts, n
```

Результати обчислень

```
--- АНАЛІЗ ТЕКСТУ З ПРОБІЛАМИ ---  
Загальна довжина: 1739185 символів  
H1 = 4.3594 біт/символ  
H2 (що перетинаються) = 3.9529 біт/символ  
H2 (що НЕ перетинаються) = 3.9528 біт/символ
```

ТОП-5 монограм (символів):

```
' ': 290859 разів (p = 0.16724)  
'о': 165181 разів (p = 0.09498)  
'е': 131101 разів (p = 0.07538)  
'а': 113136 разів (p = 0.06505)  
'н': 96152 разів (p = 0.05529)
```

ТОП-5 біграм (що перетинаються):

```
'о ': 39574 разів (p = 0.02275)  
'е ': 33656 разів (p = 0.01935)  
'и ': 33401 разів (p = 0.01920)  
'а ': 29924 разів (p = 0.01721)  
' н': 28911 разів (p = 0.01662)
```

ТОП-5 біграм (що НЕ перетинаються):

```
'о ': 19758 разів (p = 0.02272)  
'е ': 16694 разів (p = 0.01920)  
'и ': 16618 разів (p = 0.01911)  
'а ': 14937 разів (p = 0.01718)  
' н': 14355 разів (p = 0.01651)
```

```
--- АНАЛІЗ ТЕКСТУ БЕЗ ПРОБІЛІВ ---
```

```
Загальна довжина: 1448326 символів  
H1 = 4.4527 біт/символ  
H2 (що перетинаються) = 4.1357 біт/символ  
H2 (що НЕ перетинаються) = 4.1361 біт/символ
```

ТОП-5 монограм (символів):

```
'о': 165181 разів (p = 0.11405)  
'е': 131101 разів (p = 0.09052)  
'а': 113136 разів (p = 0.07812)  
'н': 96152 разів (p = 0.06639)  
'и': 95118 разів (p = 0.06567)
```

ТОП-5 біграм (що перетинаються):

```
'то': 24446 разів (p = 0.01688)  
'не': 18416 разів (p = 0.01272)  
'он': 18040 разів (p = 0.01246)  
'ст': 17953 разів (p = 0.01240)  
'но': 17593 разів (p = 0.01215)
```

ТОП-5 біграм (що НЕ перетинаються):

```
'то': 12221 разів (p = 0.01688)  
'не': 9320 разів (p = 0.01287)  
'он': 8915 разів (p = 0.01231)  
'ст': 8909 разів (p = 0.01230)  
'на': 8735 разів (p = 0.01206)
```

Зведена таблиця оцінок ентропії

Варіант тексту	Обсяг (символів)	Алфавіт m	$H_0 = \log_2 m$	H_1 (біт/симв)	H_2 (перетинаються)	H_2 (НЕ перетинаються)
3 пробілами	1 739 185	34	5.0875	4.3594	3.9529	3.9528
Без пробілів	1 448 326	33	5.0444	4.4527	4.1357	4.1361

Статистичні характеристики тексту **3 ПРОБІЛАМИ**

(Загальна довжина: 1 739 185 символів)

№	Монограми	p	Біграми (перетинаються)	p	Біграми (НЕ перетинаються)	p
1	' ' (пробіл)	0.16724	'o '	0.02275	'o '	0.02272
2	'o'	0.09498	'e '	0.01935	'e '	0.01920
3	'e'	0.07538	'и '	0.01920	'и '	0.01911

4	'а'	0.06 505	'а '	0.0172 1	'а '	0.01718
5	'н'	0.05 529	' н'	0.0166 2	' н'	0.01651

Статистичні характеристики тексту **БЕЗ ПРОБІЛІВ**
(Загальна довжина: 1 448 326 символів)

№	Монограми	р	Біграми (перетинаються)	р	Біграми (НЕ перетинаються)	р
1	'о'	0.11405	'то'	0.01688	'то'	0.016 88
2	'е'	0.09052	'не'	0.01272	'не'	0.012 87
3	'а'	0.07812	'он'	0.01246	'он'	0.012 31
4	'н'	0.06639	'ст'	0.01240	'ст'	0.012 30

5	'и'	0.06567	'но'	0.01215	'на'	0.01206
---	-----	---------	------	---------	------	---------

Аналіз отриманих результатів

Вплив пробілів на H_1 : Після видалення пробілів значення H_1 зросло з 4.3594 до 4.4527 біт/символ. Оскільки пробіл є найчастішим символом природного тексту ($p \approx 0.167$), його видалення робить розподіл ймовірностей решти 33 літер більш рівномірним, що збільшує невизначеність (ентропію).

Залежність між символами ($H_2 < H_1$): Для обох варіантів тексту $H_2 < H_1$ (для тексту з пробілами: $3.9529 < 4.3594$). Це підтверджує наявність контекстних зв'язків між сусідніми літерами в мові — знання попереднього символу зменшує невизначеність щодо наступного.

Порівняння біграм: Значення H_2 для перетинальних та неперетинальних біграм практично однакові (різниця становить лише $\approx 10^{-4}$ біта). Це пояснюється тим, що великий обсяг вибірки (≈ 1.7 млн символів) забезпечує однакове згладжування статистики при обох підходах.

3. Дослідження впливу розподілу символів на ентропію

Прогноз:

Очікуваний порядок зростання H_1 : $B < A < V$

Б - послідовність, утворена повторенням одного символу, отже невизначеності немає взагалі. Імовірність цього символу = 1, отже $H_1 = 0$.

В - розподіл рівноймовірний, а отже ентропія максимальна, $H_0 = \log_2 m$, де m - розмір алфавіту.

А - у фрагменті природного тексту символи алфавіту зустрічаються з різною частотою, отже розподіл нерівномірний ($H_1 < H_0$), але і не вироджений ($H_1 > 0$), бо послідовність утворена за допомогою різних елементів алфавіту.

```
1  # Використовує calc_h1 з lab1.py
2
3  import math
4  import random
5  import sys
6
7  from lab1 import calc_h1
8
9  N = 100_000 # довжина всіх послідовностей
10 SEED = 42
11 LETTERS = "абвгдежзийклмнопрстуфхцщщъьэюяё" # 33 літери
12
13 random.seed(SEED)
14
15
16 def run(text_path, alphabet, label):
17     print(f"\n {label}: алфавіт = {len(alphabet)} символи, "
18           f"H0 = log2({len(alphabet)}) = {math.log2(len(alphabet)):.4f} біт ")
19
20     seqs = {}
21     if text_path:
22         with open(text_path, encoding="utf-8") as f:
23             txt = f.read()
24             if " " not in alphabet:
25                 txt = txt.replace(" ", "")
26             seqs["А (природний текст)"] = txt[:N]
27     seqs["Б (один символ)"] = alphabet[0] * N
28     seqs["В (рівноймовірний random)"] = "".join(random.choices(alphabet, k=N))
29
30     for name, s in seqs.items():
31         h1 = abs(calc_h1(s)[0]) # abs прибирає "-0.0000" для Б
32         print(f" {name:28s} довжина = {len(s)} H1 = {h1:.4f} біт/символ")
33
34
35 if __name__ == "__main__":
36     path = sys.argv[1] if len(sys.argv) > 1 else None
37     run(path, LETTERS + " ", "З пробілом")
38     run(path, LETTERS, "Без пробілу")
```

```
C:\Users\robertkvadraty\k\Desktop\crypto\lab1>python lab1_3.py text_with_spaces.txt

З пробілом: алфавіт = 34 символи,  $H_0 = \log_2(34) = 5.0875$  біт
A (природний текст) довжина = 100000  $H_1 = 4.3840$  біт/символ
Б (один символ) довжина = 100000  $H_1 = 0.0000$  біт/символ
В (рівномірний random) довжина = 100000  $H_1 = 5.0873$  біт/символ

Без пробілу: алфавіт = 33 символи,  $H_0 = \log_2(33) = 5.0444$  біт
A (природний текст) довжина = 100000  $H_1 = 4.4683$  біт/символ
Б (один символ) довжина = 100000  $H_1 = 0.0000$  біт/символ
В (рівномірний random) довжина = 100000  $H_1 = 5.0441$  біт/символ
```

Результати:

(Послідовність)	З пробілом	Без пробілу
$H_1(A)$	4.3840	4.4683
$H_1(B)$	0.0000	0.0000
$H_1(V)$	5.0873	5.0441

Порівняйте отримані результати з попереднім прогнозом. Поясніть, як характер розподілу ймовірностей символів впливає на ентропію джерела.

Наш прогноз підтвердився, $H_1(B) < H_1(A) < H_1(V)$.

Отже, ентропія джерела безпосередньо залежить від того, наскільки рівномірно розподілені ймовірності символів алфавіту. Чим більш рівномірний розподіл, тим більша ентропія (тому що більша невизначеність щодо наступного символу). Вироджений розподіл (коли одне значення приймається із ймовірністю 1, тобто коли послідовність утворена повторенням одного символу) дає нульову ентропію, адже невизначеності взагалі немає.

4. Дослідження залежностей між символами

Прогноз:

- чи повинні суттєво відрізнятися значення H_1 для послідовностей Г і Д;

H_1 , значення не повинні відрізнятися, тому що H_1 обчислюється лише за частотами окремих символів, без урахування їх порядку. Обидві послідовності побудовані з однакового набору символів, просто в Г вони перемішані, а в Д розташовані періодично, частоти символів в обох послідовностях однакові.

2. чи повинні суттєво відрізнятися значення H_2 ;

Так, значення H_2 для Г і Д мають відрізнятися, адже H_2 враховує залежності між парами сусідніх символів. Порядок символів в послідовностях кардинально відрізняється, в Г вони розташовані випадковим чином, а в Д утворюють чітку періодичну структуру.

3. для якої послідовності ви очікуєте менше значення H_2 .

Менше значення H_2 ми очікуємо для Д. Через те, що в послідовності Д елементи утворюють періодичну структуру, знаючи поточний символ, можна точно вгадати наступний.

4. чи відрізнятимуться H_2 обчислене для біграм що перетинаються і що не перетинаються

Так, значення H_2 можуть трохи відрізнятися. Перетинний спосіб використовує вдвічі більше біграм, тому дає точнішу оцінку, неперетинний спосіб бачить менше пар, тому для періодичної послідовності Д розбіжність між способами може бути більш помітною, ніж для випадкової Г.

```
1  # Використовує calc_h1 та calc_h2_* з lab1.py
2
3  import random
4  from collections import Counter
5
6  from lab1 import calc_h1, calc_h2_overlapping, calc_h2_non_overlapping
7
8  N = 100_000
9  SEED = 42
10 LETTERS = "абвгдежзийклмнопрстуфхцщъьэюяё"
11
12 random.seed(SEED)
13
14
15 def run(alphabet, label):
16     print(f"\n {label} (алфавіт '{alphabet}') ")
17     k = len(alphabet)
18
19     # Д - символи утв. виражену періодичну структуру (ababab...)
20     d = (alphabet * (N // k + 1))[:N]
21
22     # Г - символи розташовані у випадковому порядку
23     letters = list(d)
24     random.shuffle(letters)
25     g = "".join(letters)
26
27     assert Counter(g) == Counter(d), "частоти символів мають збігатися"
28
29     for name, s in (("Г (випадковий порядок)", g), ("Д (періодична)", d)):
30         h1 = abs(calc_h1(s)[0])
31         h2_ov = abs(calc_h2_overlapping(s)[0])
32         h2_nov = abs(calc_h2_non_overlapping(s)[0])
33         print(f" {name:24s} H1 = {h1:.4f} "
34               f"H2 (перетин.) = {h2_ov:.4f} H2 (неперетин.) = {h2_nov:.4f}")
35
36
37 if __name__ == "__main__":
38     run("ab", "Період 2")
39     run("abcd", "Період 4")
40     run(LETTERS, "Весь алфавіт, період 33")
```

```
C:\Users\robertkvadryk\Desktop\crypto\lab1>python lab1_4.py

Період 2 (алфавіт 'ab')
Г (випадковий порядок)  H1 = 1.0000  H2 (перетин.) = 1.0000  H2 (неперетин.) = 1.0000
Д (періодична)          H1 = 1.0000  H2 (перетин.) = 0.5000  H2 (неперетин.) = 0.0000

Період 4 (алфавіт 'abcd')
Г (випадковий порядок)  H1 = 2.0000  H2 (перетин.) = 1.9999  H2 (неперетин.) = 1.9999
Д (періодична)          H1 = 2.0000  H2 (перетин.) = 1.0000  H2 (неперетин.) = 0.5000

Весь алфавіт, період 33 (алфавіт 'абвгдежзийклмнопрстуфхцшщъыьэюяё')
Г (випадковий порядок)  H1 = 5.0444  H2 (перетин.) = 5.0408  H2 (неперетин.) = 5.0367
Д (періодична)          H1 = 5.0444  H2 (перетин.) = 2.5222  H2 (неперетин.) = 2.5222
```

Результати:

	'ab'			'abcd'			весь алфавіт		
Послідовність	H ₁	H ₂ (п)	H ₂ (нп)	H ₁	H ₂ (п)	H ₂ (нп)	H ₁	H ₂ (п)	H ₂ (нп)
Г	1.0000	1.0000	1.0000	2.0000	1.9999	1.9999	5.0444	5.0408	5.0367
Д	1.0000	0.5000	0.0000	2.0000	1.0000	0.5000	5.0444	2.5222	2.5222

Порівняйте результати з прогнозом

1. Прогноз підтвердився повністю, в усіх трьох випадках H₁ Г і Д точно збігаються, що підтверджує, що H₁ залежить лише від частот символів, а не від їхнього порядку.
2. Прогноз підтвердився, в усіх трьох випадках H₂ для Г і Д суттєво відрізняються.
3. Прогноз підтвердився в усіх випадках, Д завжди має нижче значення H₂, ніж Г через те, що в Д зв'язок між сусідніми символами детермінований, тому невизначеність значно нижча.
4. Тут результат трохи відрізняється від нашого прогнозу. Для Г різниця дійсно незначна в усіх випадках, як ми і очікували. А от для Д розбіжність між способами дещо різна: для періодів 2 і 4, тобто парних, різниця значна (0.5 проти 0.0 і 1.0 проти 0.5), а для періоду 33 (непарного) значення повністю збіглися (2.5222 = 2.5222). Виявилось, що розбіжність залежить від того, чи мають період і крок вибірки (2 для неперетинних біграм) спільний дільник. Якщо мають (як у 2 і 4), неперетинний спосіб щоразу пропускає частину можливих пар. Якщо не мають (як 33 і 2, взаємно прості числа), послідовність позицій вибірки проходить через усі можливі зсуви циклу вже за 33 кроки, а при N=100000 це повторюється тисячі разів, тому статистика вирівнюється і H₂ виходять однаковими.

та поясніть:

- чому тексти з однаковими частотами окремих символів можуть мати однакові або близькі значення H_1 ;

Тому що при обчисленні H_1 враховується лише частота окремих символів, взаємне розташування цих символів, тобто їх порядок, не важливе.

- чому їхні значення H_2 можуть відрізнитися;

Тому що H_2 рахується за парами сусідніх символів, тому в цьому випадку порядок вже має значення.

- яку інформацію про джерело дозволяє врахувати модель біграм порівняно з моделлю незалежних символів.

H_1 ігнорує зв'язки між символами, H_2 враховує залежність сусідніх символів, тобто наскільки поява одного символу впливає на ймовірність наступного. Це дозволяє виявити структуру мови, яку H_1 не бачить, і дає точнішу оцінку реальної ентропії джерела.

5. Експериментальна оцінка ентропії джерела

Оцінка значення $H^{(10)}$ за допомогою програми CoolPinkProgram:

Лабораторная работа №1

Произвольная часть текста:
оторый_не_распространяется_на_животных_растения_или_на_неорганические_тела_

Использованные буквы:

Порядок n-граммы:
5 символов
10 символов
15 символов
20 символов
25 символов
30 символов
35 символов
40 символов
45 символов
50 символов

Введенный символ: _ (пробел)
Символ по счету: 1
Номер эксперимента: 56

Неравенство для энтропии:
 $1.95418358329006 < H < 2.69689775915215$

Двоичная таблица угаданных символов:
01000000000000000000000000000000
10000000000000000000000000000000
00000010000000000000000000000000
01000000000000000000000000000000
10000000000000000000000000000000

Вероятности:
q[1] = 0.4642857
q[2] = 0.1785714
q[3] = 0.0178571
q[4] = 0.0535714
q[5] = 0.0357142
q[6] = 0
q[7] = 0.0714285
q[8] = 0
q[9] = 0.0357142
q[10] = 0.017857
q[11] = 0.017857
q[12] = 0
q[13] = 0
q[14] = 0
q[15] = 0.035714
q[16] = 0
q[17] = 0
q[18] = 0
q[19] = 0
q[20] = 0.017857
q[21] = 0.017857
q[22] = 0
q[23] = 0
q[24] = 0
q[25] = 0
q[26] = 0
q[27] = 0.017857
q[28] = 0
q[29] = 0.017857
q[30] = 0
q[31] = 0
q[32] = 0

Поле ввода символов:
Продолжить Другой

Строка состояния:
Вы угадали. Для продолжения опыта нажмите "Продолжить", или "Другой" для выбора другого порядка

Оцінка значення $H^{(20)}$:

[illegible]

Оцінка значення $H^{(30)}$:

Лабораторная работа №1				
Произвольная часть текста:		Вероятности:		
разрез_с_этим_стандартом_поведения_а_если_все_таки_идет_для_этого_имеютс		q[1] = 0.6296296 q[2] = 0.1111111 q[3] = 0.0555555 q[4] = 0.0370370 q[5] = 0.0185185 q[6] = 0 q[7] = 0 q[8] = 0 q[9] = 0 q[10] = 0 q[11] = 0.018518 q[12] = 0 q[13] = 0 q[14] = 0 q[15] = 0 q[16] = 0.037037 q[17] = 0 q[18] = 0.018518 q[19] = 0.018518 q[20] = 0 q[21] = 0 q[22] = 0 q[23] = 0 q[24] = 0 q[25] = 0 q[26] = 0 q[27] = 0.018518 q[28] = 0.018518 q[29] = 0 q[30] = 0 q[31] = 0 q[32] = 0.018518		
Использованные буквы:				
з, р, к, с, м, и, т, п, а, в, е, н, г, ш, й, ф, ы, о, л, я, ч, ь, б, ю, ж, э,				
Порядок n-граммы:	Введенный символ: д	Неравенство для энтропии:		
5 символов 10 символов 15 символов 20 символов 25 символов 30 символов 35 символов 40 символов 45 символов 50 символов	Символ по счету: 27	1.40797131375195 < H < 2.10232455570047		
	Номер эксперимента: 54	Двоичная таблица угаданных символов:		
	Поле ввода символов: д	10000000000000000000000000000000 10000000000000000000000000000000 000000000000000000000000000000001 10000000000000000000000000000000 0000000000000000000010000000000000		
	Продолжить Другой			
Строка состояния: Вы угадали. Для продолжения опыта нажмите "Продолжить", или "Другой" для выбора другого порядка				

Порівняння отриманих значень:

Оцінка	Отримане значення
H_1	4.3840
H_2	3.9529
$H^{(10)}$	$1.9541 < H < 2.6968$
$H^{(20)}$	$1.8661 < H < 2.7532$
$H^{(30)}$	$1.4079 < H < 2.1023$

Аналіз отриманих результатів:

1. чому наведені оцінки ентропії не повинні обов'язково збігатися;
 H_1 і H_2 рахуються точно за частотами літер і біграм у великому тексті. $H^{(10)}$, $H^{(20)}$, $H^{(30)}$ ми отримали після того, як 50+ експериментів підряд вгадували наступний символ, тож це інша модель джерела. Вони враховують різну довжину контексту (9, 19, 29 попередніх символів), і результат залежить від людини та від вибраних уривків (іноді наступний символ був очевидний, іноді доводилось перебрати всі 34 варіанти, щоб знайти правильний). Тому CoolPinkProgram дає не одне число, а інтервал (наприклад, $1.9541 < H^{(10)} < 2.6968$).

2. які статистичні залежності враховуються при визначенні H_1 та H_2 ;
 H_1 враховує лише частоти окремих літер, порядок ігнорується, H_2 додатково враховує залежність між парою сусідніх літер.

3. чому врахування довших залежностей між символами може змінювати оцінку ентропії природної мови;
Чим більше попередніх символів відомо, тим більше людина, яка орієнтується в мові, бачить контексту, і тим простіше їй вгадати наступний символ. Після 10-30 відкритих символів вже часто видно цілі частини речень, початок або кінець слів. Невизначеність наступного символу зменшується, тому оцінка ентропії знижується.

4. яку тенденцію можна спостерігати при переході від H_1 до оцінок, що враховують дедалі довший контекст.
При збільшенні довжини контексту оцінка ентропії монотонно спадає: $H_1 > H_2 > H^{(10)} > H^{(20)} > H^{(30)}$ (з 4.3840 до інтервалу (1.4079, 2.1023)). Це ще раз підтверджує, що чим більше попередніх символів відомо, тим простіше вгадати наступний.

6. Оцінювання надлишковості джерела

Надлишковість джерела обчислюється за формулою

$$R = 1 - \frac{H_{\infty}}{H_0},$$

де $H_0 = \log_2 m$ (максимальна ентропія алфавіту)

$$H_0 = 5.0875$$

Порахую R окремо для кожної оцінки:

$$R_1 = 1 - H_1 / H_0 = 1 - 4.3840 / 5.0875 = 0.1382 \text{ (13.82\%)}$$

$$R_2 = 1 - 3.9529 / 5.0875 = 0.2230 \text{ (22.3\%)}$$

$$R^{(10)} = 0.470 - 0.616 \text{ (47\% - 61.6\%)}$$

$$R^{(20)} = 0.459 - 0.633 \text{ (45.9\% - 63.3\%)}$$

$$R^{(30)} = 0.587 - 0.723 \text{ (58.7\% - 72.3\%)}$$

Порівняння отриманих оцінок:

1. як змінюється оцінка надлишковості при врахуванні залежностей між символами;

Надлишковість $R = 1 - H/H_0$ зростає, коли модель враховує більше залежностей. Найменшу R дає H_1 (враховує лише частоти літер), трохи більшу H_2 (додається зв'язок з попередньою літерою), а найбільшу оцінки $H^{(10)}$, $H^{(20)}$, $H^{(30)}$, бо довший контекст знижує ентропію.

2. чому природна мова має ненульову надлишковість;

Мова це не випадкова послідовність символів. Літери мають нерівні частоти, а між ними існують залежності: склади, закінчення, типові поєднання, цілі слова. Через це наступний символ частково передбачуваний, і ентропія H_{∞} менша за максимум $H_0 = \log_2 m$. Різниця між ними і є надлишковістю, тобто частиною символів, яка не несе нової інформації.

Те, що природна мова має ненульову надлишковість, дуже важливо, адже саме через це ми можемо зрозуміти зміст тексту, який містить пропуски, друкарські помилки, можемо розібрати мову в шумному місці.

3. який зв'язок існує між передбачуваністю наступних символів тексту, ентропією та надлишковістю джерела.

Чим передбачуваніше наступний символ, тим менша невизначеність, а отже менша ентропія. Чим менша ентропія відносно H_0 , тим більша надлишковість. У рівномірної випадкової послідовності ентропія дорівнює H_0 , тому $R = 0$; у послідовності з одним символом ентропія 0, тому $R = 1$. Природна мова лежить між ними.

Аналіз результатів:

1. Чому природний текст має меншу ентропію на символ, ніж випадкова рівноймовірна послідовність символів того самого алфавіту?

У природному тексті літери мають нерівні частоти (пробіл, «о», «е» частіше за «щ», «ъ»), а сусідні літери залежні одна від одної. Тому наступний символ можна частково передбачити. У послідовності В усі символи рівноймовірні й незалежні, тому невизначеність максимальна: $H_1(B) = 5.0873 \approx H_0 = \log_2 34 = 5.0875$. Для природного тексту H_1 буде помітно нижчою (4.3840), а оцінки $H^{(n)}$ ще нижчі (1.4–2.8 біта).

2. Яку інформацію про джерело враховує H_2 , але не враховує H_1 ?

H_2 враховує залежність між сусідніми символами (яка літера частіше йде після якої). H_1 рахується лише за частотами окремих літер, порядок ігнорується.

3. Чи можуть два тексти мати однакове H_1 , але різне H_2 ? Наведіть приклад із виконаних експериментів.

Так, можуть, наведу приклад з експерименту 4: Г і Д мають однакові частоти символів, тому H_1 однакові (1.0000, 2.0000, 5.0444), але H_2 різні. Для повного алфавіту $H_2(\Gamma) = 5.0408$, а $H_2(D) = 2.5222$ (біграми, що перетинаються). Різниця виникає лише через порядок символів: у Д він періодичний, у Г випадковий.

4. Як вилучення пробілів вплинуло на отримані значення ентропії? Поясніть отриманий результат.

	З пробілом	Без пробілу
H_1	4.3594	4.4527
H_2 (перетин.)	3.9529	4.1357
H_2 (неперетин.)	3.9528	4.1361

Вилучення пробілів підвищило і H_1 , і H_2 , приблизно на 0.09–0.18 біта на символ.

Пробіл виявився найчастішим символом тексту: з таблиці ТОП-5 видно, що він трапляється з ймовірністю $p = 0.16724$, тобто майже вдвічі частіше за найпоширенішу літеру «о» ($p = 0.09498$). Такий домінуючий символ сильно «тягне» розподіл ймовірностей у бік нерівномірності, а нерівномірність розподілу знижує ентропію.

Коли пробіл прибрали, залишилися тільки 33 літери, і їхні відносні частоти між собою стали вищими й трохи вирівнялись (бо зникла та величезна частка

«найчастішого» символу, яка раніше домінувала над усіма іншими). Розподіл серед літер став ближчим до рівномірного, тому H_1 і H_2 зросли.

5. Чому оцінки H_2 , отримані за біграмами, що перетинаються та не перетинаються, можуть дещо відрізнятися?

Перетинний спосіб використовує вдвічі більше біграм (бо кожен символ входить у дві пари), тож статистика більш точна. Неперетинний бачить вдвічі менше пар, тому оцінка має більшу похибку (для випадкової Γ : 5.0408 проти 5.0367). Для періодичної D різниця залежить від співвідношення періоду й кроку 2: для періодів 2 і 4 різниця велика (0.5 проти 0.0; 1.0 проти 0.5), для 33 значення збіглися (2.5222).

6. Чому значення H_1 , H_2 , $H^{(10)}$, $H^{(20)}$ та $H^{(30)}$ відрізняються?

Вони відрізняються, тому що кожна оцінка враховує різну довжину контексту: H_1 враховує частоту лише одного символу, тобто довжина контексту - 0, H_2 один, $H^{(n)}$ до $n-1$ символів. Чим довший контекст, тим більше закономірностей (склади, слова, фрази) можна використати і тим нижча оцінка. Крім цього, H_1 і H_2 рахуються точно за частотами, а $H^{(n)}$ методом вгадування людиною, який дає інтервал і залежить від досвіду учасника. Тому інтервали $H^{(10)}$ і $H^{(20)}$ частково перекриваються (1.9541–2.6968 і 1.8661–2.7532), а $H^{(30)}$ нижча (1.4079–2.1023).

7. Який із проведених експериментів найкраще демонструє наявність залежностей між послідовними символами?

Експеримент 4 (Γ проти D) найкраще це демонструє. У них однакові частоти символів, тому H_1 збігаються, але $H_2(D)$ майже вдвічі менша за $H_2(\Gamma)$ для 33 символів (2.5222 проти 5.0408). Різницю дає лише порядок, а отже зв'язок між сусідніми символами. Додатково це підтверджує падіння оцінок $H^{(n)}$ порівняно з H_1 на природному тексті.

8. Як отримані результати пов'язані з можливістю стиснення природного тексту без втрати інформації?

Надлишковість ($R = 1 - H/H_0$) показує частку символів, яку можна прибрати без втрати змісту. Для $H^{(n)}$ $R \approx 0.46-0.72$ (при $H_0 = 5.0875$), тобто в принципі текст можна стиснути в кілька разів. Ентропія задає теоретичну межу стиснення: не можна закодувати текст у середньому коротше за H біт на символ. Довші контексти дають нижчу H , тому кращі архіватори враховують саме довші залежності, а не лише частоти літер (H_1).

Висновок: У цій лабораторній роботі ми дослідили поняття ентропії на символ джерела відкритого тексту та його надлишковості на прикладі роману Т. Драйзера «Американська трагедія».

Ми реалізували програму для обчислення ентропії за частотами монограм (H_1) та біграм, що перетинаються і не перетинаються (H_2), а також провели експерименти з різними послідовностями символів.

Експеримент із послідовностями А, Б і В показав, що ентропія джерела повністю визначається розподілом ймовірностей символів: вироджений розподіл (Б) дає $H_1 = 0$, рівномірний розподіл (В) дає $H_1 \approx H_0 = \log_2 m$ ($5.0873 \approx 5.0875$), а природний текст (А) з нерівномірними частотами літер дає проміжне значення ($H_1 = 4.3840$).

Експеримент із послідовностями Г і Д довів, що H_1 не чутлива до порядку символів і залежить лише від їхніх частот ($H_1(\Gamma) = H_1(D)$ в усіх випадках), тоді як H_2 суттєво залежить від порядку, оскільки враховує зв'язок між сусідніми символами. Для періодичної структури H_2 виявилась значно нижчою, ніж для випадкової (наприклад, 2.5222 проти 5.0408 для повного алфавіту).

Для аналізованого роману ми отримали такі оцінки: послідовне зниження ентропії зі збільшенням врахованого контексту: $H_1 = 4.3840 > H_2 = 3.9529 > H^{(10)} > H^{(20)} > H^{(30)}$ (до інтервалу 1.41–2.10 біт/символ). Це підтверджує, що чим довша залежність між символами враховується, тим точніше (і нижче) оцінюється справжня ентропія мови, бо довгий контекст розкриває закономірності (слова, фрази), приховані для коротких моделей.

Обчислена надлишковість зростає від $R_1 \approx 13.8\%$ до $R^{(30)} \approx 59\text{--}72\%$ зі збільшенням врахованого контексту, що демонструє: чим точніша модель джерела, тим більша частка «передбачуваної», а отже стисливої, інформації в тексті вдається виявити.